Bayesian Spatial Modeling of air pollution using Gaussian Processes

Monica Bagnasco

Politecnico di Torino

Introduzione

Nel dataset `data_clean` si osserva, per ciascuna città/stazione $i = 1, \dots, n$, la risposta

$$y_i = \log(\text{PM10}_i),$$

misurata in una posizione spaziale $s_i = (s_{i1}, s_{i2})$, dove nel codice $s_{i1} =$ `X` e $s_{i2} =$ `Y`. Si assume il modello gerarchico:

$$Y(s_i) = \mu + \beta_1 s_{i1} + \beta_2 s_{i2} + W(s_i) + \varepsilon_i, \tag{1}$$

$$\varepsilon_i \overset{iid}{\sim} \mathcal{N}(0, \tau^2), \tag{2}$$

$$\mathbf{W} = (W(s_1), \dots, W(s_n))^\top \sim \mathcal{N}\big(\mathbf{0},\, \Sigma_W\big), \tag{3}$$

dove $\Sigma_W = \sigma^2 R(\phi)$ e la matrice di correlazione $R(\phi)$ ha elementi

$$[R(\phi)]_{ij} = \exp\{-\phi\, h_{ij}\}, \qquad h_{ij} = \|s_i - s_j\|.$$

Questa è la covarianza esponenziale: dipende solo dalla distanza h ed è positiva definita su spazi euclidei.
Nel seguito si indica con:

$$\mathbf{y} = (y_1, \dots, y_n)^\top, \qquad X = \begin{pmatrix} 1 & s_{11} & s_{12} \\ \vdots & \vdots & \vdots \\ 1 & s_{n1} & s_{n2} \end{pmatrix}, \qquad \beta = (\mu, \beta_1, \beta_2)^\top,$$

così che il modello al primo livello diventa

$$\mathbf{y} \mid \mathbf{w}, \beta, \tau^2 \sim \mathcal{N}\big(X\beta + \mathbf{w},\, \tau^2 I_n\big), \quad \text{con } \mathbf{w} = \mathbf{W}.$$

Punto 1

Il grafico richiesto consiste nel rappresentare le coordinate (X, Y) dei punti osservati colorandoli in base al valore di $y = \log(\text{PM10})$. Questa visualizzazione serve per:

- Evidenziare pattern spaziali: aree con valori simili (colori simili) che risultano vicine indicano dipendenza spaziale positiva.
- Individuare eventuali trend/gradiente: se i colori variano in modo sistematico lungo una direzione, può essere presente un effetto delle coordinate (trend) che motiva l'inclusione di $\beta_1 s_1 + \beta_2 s_2$.

Se $W(s)$ è un processo Gaussiano con covarianza esponenziale, allora la correlazione tra due siti decresce monotonicamente con la distanza:

$$\text{Corr}(W(s_i), W(s_j)) = \exp\{-\phi h_{ij}\}.$$

Quindi, in presenza di dipendenza spaziale, ci si aspetta continuità spaziale del segnale (zone omogenee), coerente con le proprietà dei processi stazionari.
In Figura 1 è riportata la rappresentazione spaziale del logaritmo delle concentrazioni di PM10. Ogni punto corrisponde a una stazione/città del dataset ed è posizionato secondo le coordinate spaziali (X, Y); il colore del punto rappresenta il valore osservato di $Y(s) = \log(\text{PM10})$, con tonalità più calde associate a valori più elevati e tonalità più fredde a valori più bassi.

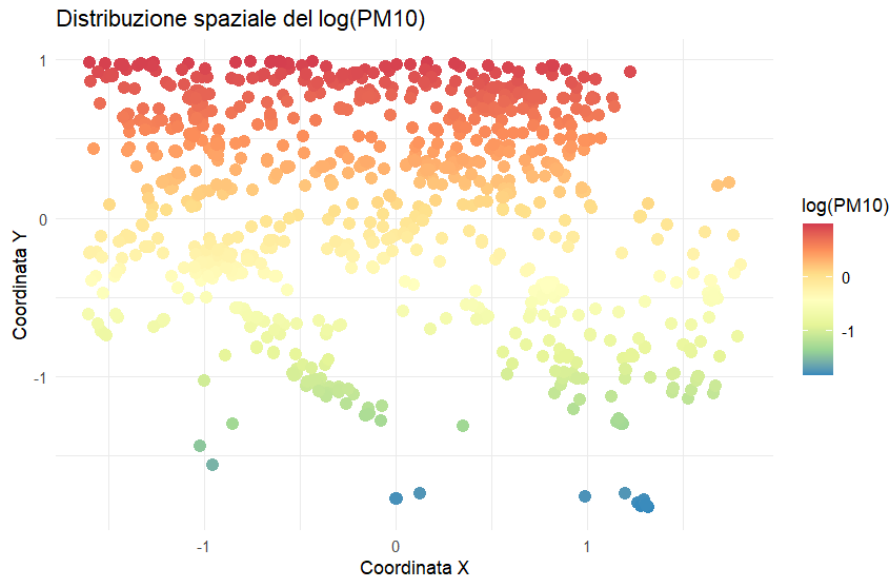


Figura 1: Distribuzione spaziale del log(PM10).

Dalla figura emerge una struttura spaziale marcata. In particolare, si osserva un gradiente verticale: i valori più elevati di log(PM10) (colori rosso–arancio) si concentrano prevalentemente nelle regioni con coordinate Y più alte, mentre valori più bassi (verde–blu) sono associati a coordinate Y più basse. Questo comportamento suggerisce la presenza di un effetto sistematico delle coordinate, che giustifica l'inclusione di un termine di trend lineare $\beta_1 s_1 + \beta_2 s_2$ nel modello.
Inoltre, punti spazialmente vicini tendono ad assumere colori simili, indicando che osservazioni prossime nello spazio presentano valori di PM10 comparabili. Questa evidenza empirica è coerente con l'ipotesi di dipendenza spaziale positiva e supporta la scelta di modellare il termine residuo strutturato $W(s)$ come un processo Gaussiano stazionario con funzione di covarianza esponenziale. Secondo tale modello, la correlazione tra $W(s_i)$ e $W(s_j)$ decresce monotonicamente con la distanza h_{ij}, producendo superfici spaziali lisce e continuità locale, caratteristiche chiaramente riscontrabili nella mappa osservata.

Punto 2: modello Bayesiano e costruzione dell'MCMC

Il codice seleziona un sottoinsieme casuale di $n_{\text{sub}} = 150$ osservazioni. Questa scelta è principalmente computazionale: con un GP pieno, ad ogni iterazione occorre lavorare con matrici $n \times n$ (Cholesky, inversa/solve), con costo tipico $O(n^3)$. Ridurre n rende l'algoritmo praticabile su un PC standard, in linea con l'osservazione nelle slides secondo le quali l'inversione della matrice di covarianza è il collo di bottiglia dei GP.

Costruzione delle distanze e vincoli per ϕ

Matrice delle distanze. Dato l'insieme di coordinate $\{s_i\}_{i=1}^n$, si calcola la matrice delle distanze euclidee

$$H = (h_{ij})_{i,j=1}^n, \qquad h_{ij} = \|s_i - s_j\|.$$

Da H si estraggono:

$$d_{\min} = \min\{h_{ij} : h_{ij} > 0\}, \qquad d_{\max} = \max\{h_{ij}\}.$$

Si esclude lo zero per evitare la distanza di un punto da se stesso.

Prior uniforme per ϕ. Si impone la prior:

$$\phi \sim \mathcal{U}\Big(\frac{3}{d_{\max}}, \frac{3}{d_{\min}}\Big).$$

Questa scelta è coerente con la traccia.

Interpretazione del range. Per covarianza esponenziale:

$$\text{Corr}(h) = \exp(-\phi h).$$

Se $h = 3/\phi$, allora $\text{Corr}(h) = e^{-3} \approx 0.05$. Quindi l'intervallo scelto per ϕ equivale a dire che la distanza a cui la correlazione scende circa al 5% è plausibilmente compresa tra $d_{\min}$ e $d_{\max}$:

$$h_{0.05} = \frac{3}{\phi} \in [d_{\min}, d_{\max}].$$

Questo rende la prior debole ma calibrata alle scale spaziali osservate.

Priors debolmente informative

Coefficienti del trend.

$$\beta \sim \mathcal{N}(b_0, V_0), \qquad b_0 = \mathbf{0}, \quad V_0 = 10^4 I_3.$$

Una varianza 10^4 implica una deviazione standard 100: su scala log(PM10) è molto ampia, quindi è una prior poco informativa (ma numericamente stabile).

Varianze.

$$\tau^2 \sim \text{IG}(a_\tau, b_\tau), \qquad \sigma^2 \sim \text{IG}(a_\sigma, b_\sigma),$$

con $a_\tau = b_\tau = a_\sigma = b_\sigma = 1$. Questa scelta è standard per mantenere full conditional in forma chiusa (Gamma inversa).

L'MCMC è un Gibbs sampler per tutti i parametri con full conditional note, combinato con un passo Metropolis-Hastings per ϕ.

Derivazione delle full conditional

Per arrivare alle formule utilizzate nel Gibbs sampler, si parte dal kernel della posteriori:

$$f(\beta, \mathbf{w}, \tau^2, \sigma^2, \phi \mid \mathbf{y}) \;\propto\; f(\mathbf{y} \mid \beta, \mathbf{w}, \tau^2)\; f(\mathbf{w} \mid \sigma^2, \phi)\; f(\beta)\; f(\tau^2)\; f(\sigma^2)\; f(\phi).$$

Poiché ϕ entra in modo non lineare nella matrice di correlazione $R(\phi)$, la sua full conditional non è in forma standard e verrà aggiornata con Metropolis–Hastings; per gli altri parametri si ottengono full conditional in forma chiusa grazie alla coniugatezza.

Full conditional di w: completamento del quadrato

La likelihood è:

$$\mathbf{y} \mid \beta, \mathbf{w}, \tau^2 \sim \mathcal{N}(X\beta + \mathbf{w}, \tau^2 I),$$

quindi (a meno di costanti)

$$f(\mathbf{y} \mid \beta, \mathbf{w}, \tau^2) \;\propto\; (\tau^2)^{-n/2} \exp\left\{ -\frac{1}{2\tau^2} (\mathbf{y} - X\beta - \mathbf{w})^\top (\mathbf{y} - X\beta - \mathbf{w}) \right\}.$$

La prior di $\mathbf{w}$ è:

$$\mathbf{w} \mid \sigma^2, \phi \sim \mathcal{N}(\mathbf{0}, \Sigma), \qquad \Sigma = \sigma^2 R(\phi),$$

quindi

$$f(\mathbf{w} \mid \sigma^2, \phi) \;\propto\; |\Sigma|^{-1/2} \exp\left\{ -\frac{1}{2} \mathbf{w}^\top \Sigma^{-1} \mathbf{w} \right\}.$$

Moltiplicando likelihood e prior e raccogliendo i termini dipendenti da $\mathbf{w}$:

$$\log f(\mathbf{w} \mid \cdot) = -\frac{1}{2\tau^2} (\mathbf{w} - (\mathbf{y} - X\beta))^\top (\mathbf{w} - (\mathbf{y} - X\beta)) - \frac{1}{2} \mathbf{w}^\top \Sigma^{-1} \mathbf{w} + \text{cost}.$$

Espandendo e raccogliendo i termini quadratici e lineari in $\mathbf{w}$:

$$\log f(\mathbf{w} \mid \cdot) = -\frac{1}{2} \mathbf{w}^\top \Big(\Sigma^{-1} + \tau^{-2} I \Big) \mathbf{w} + \mathbf{w}^\top \Big(\tau^{-2} (\mathbf{y} - X\beta) \Big) + \text{cost}.$$

Questa è la forma canonica del log-kernel di una normale multivariata. Completando il quadrato si ottiene:

$$\mathbf{w} \mid \cdot \sim \mathcal{N}(m_w, V_w), \quad V_w = \Big(\Sigma^{-1} + \tau^{-2} I \Big)^{-1}, \quad m_w = V_w \Big(\tau^{-2} (\mathbf{y} - X\beta) \Big).$$

Quindi la formula della varianza V_w nasce direttamente dal termine quadratico nel kernel.

Full conditional di β

Condizionando su $\mathbf{w}$, si ha il modello:

$$\mathbf{y} - \mathbf{w} = X\beta + \varepsilon, \qquad \varepsilon \sim \mathcal{N}(0, \tau^2 I).$$

Con prior $\beta \sim \mathcal{N}(b_0, V_0)$, il kernel della posteriori di β è:

$$\log f(\beta \mid \cdot) = -\frac{1}{2\tau^2} (\mathbf{y} - \mathbf{w} - X\beta)^\top (\mathbf{y} - \mathbf{w} - X\beta) - \frac{1}{2} (\beta - b_0)^\top V_0^{-1} (\beta - b_0) + \text{cost}.$$

Raccogliendo i termini quadratici in β:

$$\log f(\beta \mid \cdot) = -\frac{1}{2}\beta^\top \Big(\tau^{-2} X^\top X + V_0^{-1}\Big)\beta + \beta^\top \Big(\tau^{-2} X^\top (\mathbf{y} - \mathbf{w}) + V_0^{-1} b_0\Big) + \text{cost}.$$

Da qui, ancora per completamento del quadrato, segue:

$$\beta \mid \cdot \sim \mathcal{N}(m_\beta, V_\beta), \quad V_\beta = \Big(\tau^{-2} X^\top X + V_0^{-1}\Big)^{-1}, \quad m_\beta = V_\beta \Big(\tau^{-2} X^\top (\mathbf{y} - \mathbf{w}) + V_0^{-1} b_0\Big).$$

Anche in questo caso la formula della varianza V_β è determinata dal coefficiente del termine quadratico in β nel kernel.

Full conditional di τ^2

Dato $\mathbf{r} = \mathbf{y} - X\beta - \mathbf{w}$, la likelihood in τ^2 è:

$$f(\mathbf{y} \mid \beta, \mathbf{w}, \tau^2) \propto (\tau^2)^{-n/2} \exp\left\{-\frac{1}{2\tau^2}\mathbf{r}^\top \mathbf{r}\right\}.$$

Con prior $\tau^2 \sim \text{IG}(a_\tau, b_\tau)$ (densità $\propto (\tau^2)^{-(a_\tau+1)} \exp(-b_\tau/\tau^2)$), il kernel a posteriori diventa:

$$f(\tau^2 \mid \cdot) \propto (\tau^2)^{-(a_\tau+1+n/2)} \exp\left\{-\frac{b_\tau + \mathbf{r}^\top \mathbf{r}/2}{\tau^2}\right\},$$

che è ancora una Gamma inversa:

$$\tau^2 \mid \cdot \sim \text{IG}\Big(a_\tau + \frac{n}{2},\ b_\tau + \frac{1}{2}\mathbf{r}^\top \mathbf{r}\Big).$$

Questa derivazione mostra che i parametri dell'IG derivano dall'esponente di τ^2 e dal termine in $1/\tau^2$ nel kernel.

Full conditional di σ^2

Poiché $\mathbf{w} \mid \sigma^2, \phi \sim \mathcal{N}(0, \sigma^2 R)$, la densità (a meno di costanti) è:

$$f(\mathbf{w} \mid \sigma^2, \phi) \propto (\sigma^2)^{-n/2} |R|^{-1/2} \exp\left\{-\frac{1}{2\sigma^2}\mathbf{w}^\top R^{-1} \mathbf{w}\right\}.$$

Con prior $\sigma^2 \sim \text{IG}(a_\sigma, b_\sigma)$ si ottiene:

$$f(\sigma^2 \mid \cdot) \propto (\sigma^2)^{-(a_\sigma+1+n/2)} \exp\left\{-\frac{b_\sigma + \mathbf{w}^\top R^{-1}\mathbf{w}/2}{\sigma^2}\right\},$$

quindi

$$\sigma^2 \mid \cdot \sim \text{IG}\Big(a_\sigma + \frac{n}{2},\ b_\sigma + \frac{1}{2}\mathbf{w}^\top R^{-1}\mathbf{w}\Big).$$

Il termine $\mathbf{w}^\top R^{-1}\mathbf{w}$ per stabilità numerica viene calcolato via Cholesky di R senza costruire R^{-1} esplicitamente.

Likelihood e prior.

$$\mathbf{y} \mid \mathbf{w}, \beta, \tau^2 \sim \mathcal{N}(X\beta + \mathbf{w}, \tau^2 I), \qquad \mathbf{w} \mid \sigma^2, \phi \sim \mathcal{N}(\mathbf{0}, \sigma^2 R(\phi)).$$

Poiché entrambe sono gaussiane, la full conditional è ancora gaussiana (coniugio).

Forma esplicita e implementazione nel codice. Come è stato mostrato, la full conditional di $\mathbf{w}$ è una normale multivariata:

$$\mathbf{w} \mid \cdot \sim \mathcal{N}\big(m_w,\, V_w\big),$$

con

$$V_w = \Big(\Sigma^{-1} + \tau^{-2} I\Big)^{-1}, \qquad m_w = V_w\Big(\tau^{-2}(\mathbf{y} - X\beta)\Big), \quad \Sigma = \sigma^2 R(\phi).$$

Nel codice, questa distribuzione viene campionata costruendo la matrice di covarianza $\Sigma = \sigma^2 \exp(-\phi H)$ e utilizzando la fattorizzazione di Cholesky per simulare in modo numericamente stabile una normale multivariata.
Condizionando su $\mathbf{w}$, il modello si riduce a una regressione lineare gaussiana per β:

$$\mathbf{y} - \mathbf{w} = X\beta + \varepsilon, \qquad \varepsilon \sim \mathcal{N}(0, \tau^2 I),$$

che, grazie alla prior gaussiana $\beta \sim \mathcal{N}(b_0, V_0)$, conduce per coniugio alla full conditional:

$$\beta \mid \cdot \sim \mathcal{N}(m_\beta, V_\beta),$$

con

$$V_\beta = \Big(\tau^{-2} X^\top X + V_0^{-1}\Big)^{-1}, \qquad m_\beta = V_\beta\Big(\tau^{-2} X^\top (\mathbf{y} - \mathbf{w}) + V_0^{-1} b_0\Big).$$

Nel caso considerato $b_0 = \mathbf{0}$, semplificando ulteriormente l'espressione della media a posteriori.

ϕ richiede l'utilizzo del Metropolis-Hastings perchè è presente in modo non lineare dentro $R(\phi) = \exp(-\phi H)$ e quindi:

- non esiste, in generale, una full conditional standard da cui campionare direttamente;
- è però possibile calcolare il kernel della densità a posteriori (tramite la densità di $\mathbf{w}$ dato ϕ) e quindi usare Metropolis–Hastings.

Risoluzione. La prior impone $\phi \in [\phi_{\min}, \phi_{\max}]$. Una proposta normale diretta su ϕ rischia di generare valori fuori intervallo, quindi si introduce una variabile libera $u \in \mathbb{R}$ e una trasformazione biunivoca:

$$\phi(u) = \phi_{\min} + (\phi_{\max} - \phi_{\min}) \frac{e^u}{1 + e^u}.$$

Così ogni $u \in \mathbb{R}$ produce automaticamente ϕ nel range corretto.

Jacobiano. Il MH va fatto sulla densità di u, che include il termine di trasformazione:

$$\log \pi(u \mid \cdot) = \log f(\mathbf{w} \mid \sigma^2, \phi(u)) + \log \left| \frac{d\phi}{du} \right| + \text{cost}.$$

Derivando:

$$\frac{d\phi}{du} = (\phi_{\max} - \phi_{\min}) \frac{e^u}{(1 + e^u)^2},$$

quindi

$$\log \left| \frac{d\phi}{du} \right| = \log(\phi_{\max} - \phi_{\min}) + u - 2\log(1 + e^u),$$

che coincide con la funzione `log_jacobian` nel codice.
Si usa una random walk proposal:

$$u^\star \sim \mathcal{N}(u,\ s^2_{\text{prop}}),$$

simmetrica, quindi i termini di proposta si cancellano nel rapporto. L'accettazione è:

$$\alpha = \min \left\{ 1, \exp\Big(\log \pi(u^\star \mid \cdot) - \log \pi(u \mid \cdot) \Big) \right\}.$$

Con proposta simmetrica il rapporto MH dipende solo dal rapporto delle densità target.

Motivazione della proposta adattiva. La scelta di s_{prop} è critica:

- se troppo piccolo, α è spesso vicino a 1 ma la catena si muove poco (alta autocorrelazione);
- se troppo grande, si accetta raramente (catena bloccata).

Euristicamente si cerca a un acceptance rate intorno a 0.25

Aggiornamento adattivo. Il codice aggiorna la deviazione standard dopo batch di lunghezza fissata, usando una regola del tipo:

$$s_{\text{prop}} \leftarrow \exp\Big(\log s_{\text{prop}} + \gamma_b(\bar{\alpha} - \alpha^\star) \Big),$$

dove $\bar{\alpha}$ è l'accettazione media nell'ultimo batch e γ_b decresce con l'iterazione. Nel codice:

$$\gamma_b = \frac{A}{B + i},$$

che è una forma della classe $\gamma_b = A/(D + b)$ nelle slides.

Struttura complessiva dell'algoritmo (Gibbs + MH)

Ad ogni iterazione $i = 1, \ldots,$ `nsim`:

1. Campiona $\mathbf{w}$ da $\mathbf{w} \mid \mathbf{y}, \beta, \tau^2, \sigma^2, \phi$ (Normale multivariata).
2. Campiona β da $\beta \mid \mathbf{y}, \mathbf{w}, \tau^2$ (Normale multivariata).
3. Campiona τ^2 da $\tau^2 \mid \mathbf{y}, \mathbf{w}, \beta$ (Gamma inversa).
4. Campiona σ^2 da $\sigma^2 \mid \mathbf{w}, \phi$ (Gamma inversa).
5. Aggiorna ϕ via MH su u con trasformazione e Jacobiano.

Secondo la logica del Metropolis-within-Gibbs: si usano full conditional dove disponibili e MH dove non lo sono.

Burn-in e thinning

Dopo aver generato `nsim` iterazioni, si scartano le prime `burn` iterazioni (burn-in) per ridurre l'effetto dell'inizializzazione e si mantiene un campione ogni `thin` per ridurre l'autocorrelazione.

Traceplot dei parametri del modello

In questa sezione si analizzano nel dettaglio i traceplot dei campioni posteriori dei principali parametri del modello:

$$\mu,\ \beta_1,\ \beta_2,\ \tau^2,\ \sigma^2,\ \phi.$$

I traceplot servono per valutare la convergenza dell'algoritmo MCMC e la qualità del mixing. Una catena ben convergente deve oscillare attorno a un livello stabile senza trend evidenti e senza lunghi periodi di stallo.

Parametro μ (intercetta)

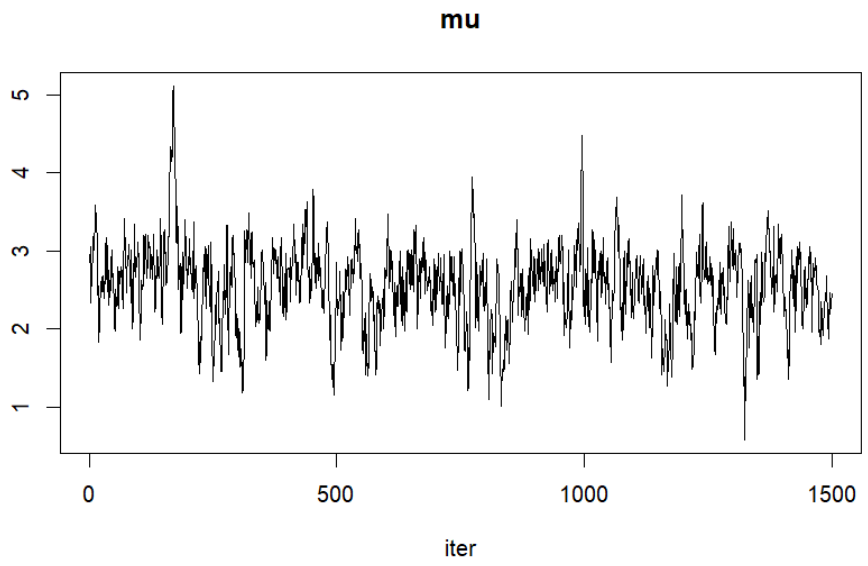


Figura 2: Traceplot dei campioni posteriori del parametro μ.

Il traceplot di μ (Figura 2) mostra oscillazioni attorno a un valore medio stabile, senza evidenza di trend sistematici o cambiamenti strutturali nel tempo. Ciò suggerisce che la catena ha raggiunto la distribuzione stazionaria a posteriori e che il burn-in adottato è adeguato. Il parametro μ rappresenta il livello medio globale del log(PM10) e la sua buona stabilità indica che tale livello è ben identificato dai dati.

Parametro β_1 (coefficiente della coordinata X)

Il traceplot di β_1 (Figura 3) evidenzia una catena che oscilla regolarmente attorno a un valore centrale, con buona esplorazione dello spazio dei parametri. Non si osservano periodi di blocco o instabilità numeriche. Questo comportamento indica un mixing soddisfacente e consente di stimare in modo affidabile l'effetto della coordinata X sul log(PM10).

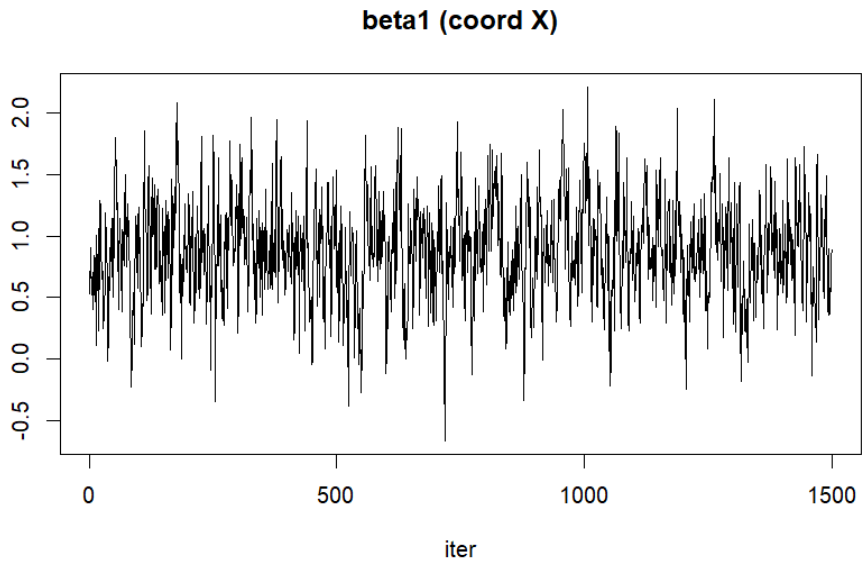


Figura 3: Traceplot dei campioni posteriori di β_1 (effetto della coordinata X).

Parametro β_2 (coefficiente della coordinata Y)

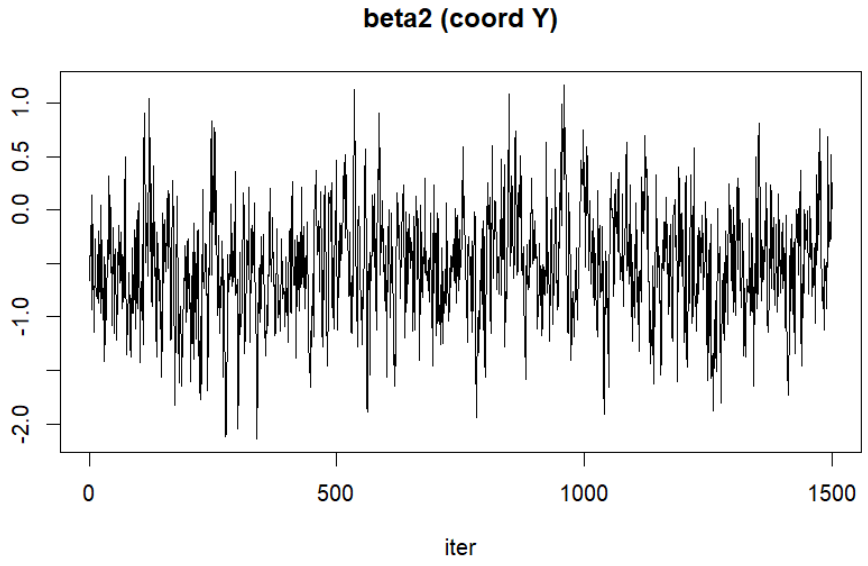


Figura 4: Traceplot dei campioni posteriori di β_2 (effetto della coordinata Y).

Il traceplot di β_2 (Figura 4) mostra una dinamica analoga a quella di β_1, con oscillazioni stazionarie e assenza di trend. La variabilità osservata riflette l'incertezza a posteriori sull'effetto della coordinata Y. Un eventuale spostamento dell'intervallo credibile lontano da zero, analizzato separatamente, fornisce evidenza di un gradiente spaziale coerente con quanto osservato nella mappa esplorativa del Punto 1.

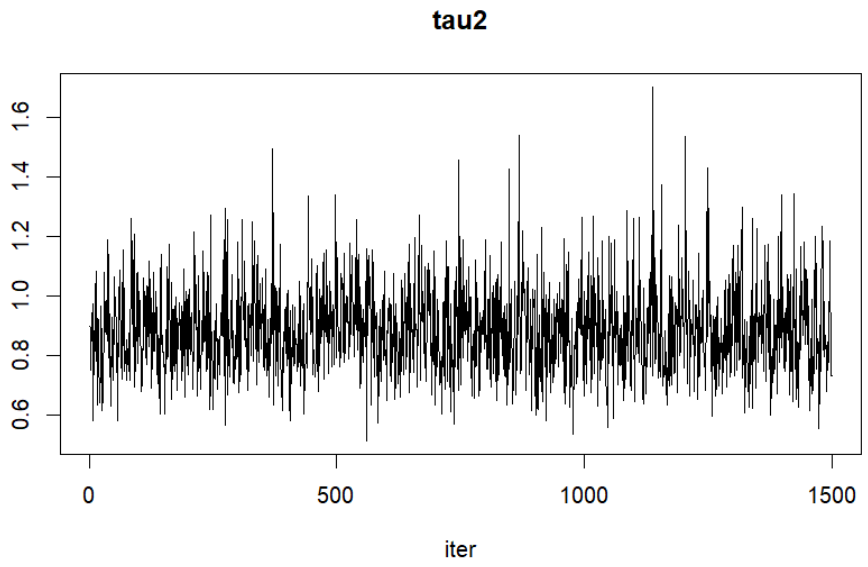


Figura 5: Traceplot dei campioni posteriori della varianza nugget τ^2.

Parametro τ^2

Il parametro τ^2 rappresenta la varianza del rumore (errore di misura o variabilità microscopica). Il traceplot in Figura 5 mostra una catena stabile, con oscillazioni attorno a un valore medio ben definito. L'assenza di trend suggerisce che la separazione tra rumore e componente spaziale strutturata è ben identificata dal modello.

Parametro σ^2 (varianza spaziale)

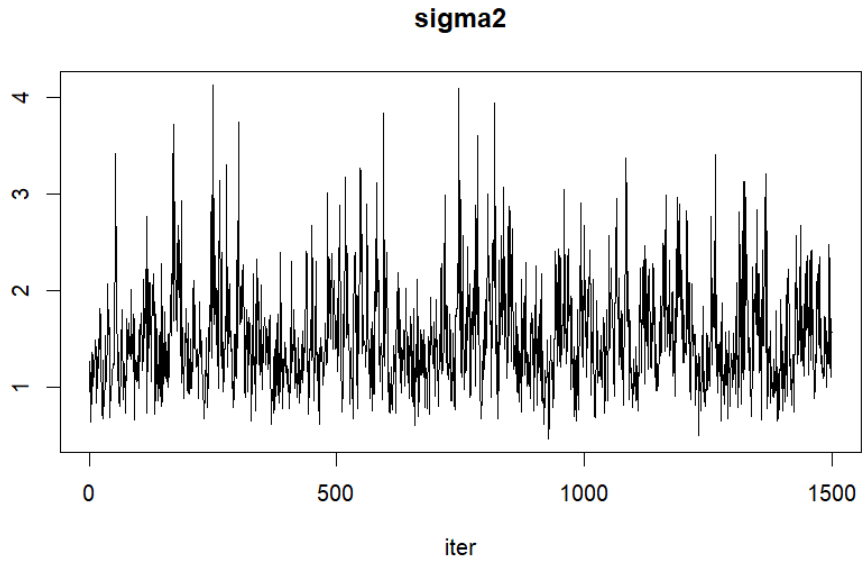


Figura 6: Traceplot dei campioni posteriori della varianza spaziale σ^2.

Il traceplot di σ^2 (Figura 6) evidenzia una maggiore variabilità rispetto a τ^2, aspetto tipico dei modelli con processi Gaussiani. Tuttavia, la catena rimane chiaramente stazionaria. Questo parametro quantifica l'intensità della dipendenza spaziale residua e la sua dinamica riflette l'incertezza sulla forza della struttura spaziale, non spiegata dal trend deterministico.

Parametro ϕ (parametro di range spaziale)

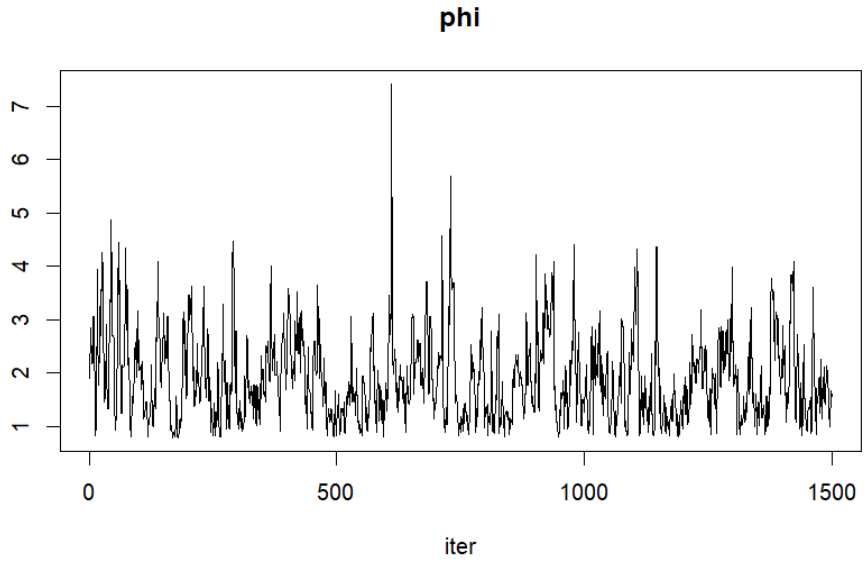


Figura 7: Traceplot dei campioni posteriori del parametro ϕ.

Il parametro ϕ controlla la velocità di decadimento della covarianza spaziale con la distanza. Il traceplot in Figura 7 mostra fluttuazioni più pronunciate rispetto agli altri parametri, fenomeno comune per i parametri di dipendenza spaziale stimati tramite Metropolis–Hastings. Nonostante ciò, la catena esplora in modo efficace l'intervallo di supporto imposto dalla prior, senza rimanere confinata in regioni ristrette.

Considerazioni conclusive

Nel complesso, l'analisi dei traceplot dei sei parametri principali suggerisce che l'algoritmo MCMC implementato presenta:

- buona convergenza verso la distribuzione a posteriori;
- mixing soddisfacente per i parametri del trend e delle varianze;
- una dinamica più lenta ma comunque accettabile per il parametro ϕ, tipica dei modelli spaziali.

Per valutare più formalmente la dipendenza seriale dei campioni di ϕ, in Figura 8 è riportata la funzione di autocorrelazione (ACF) dei campioni posteriori di tale parametro.

L'ACF mostra una autocorrelazione positiva significativa ai primi lag, che decresce progressivamente fino a diventare trascurabile dopo circa 10–15 lag. Questo comportamento

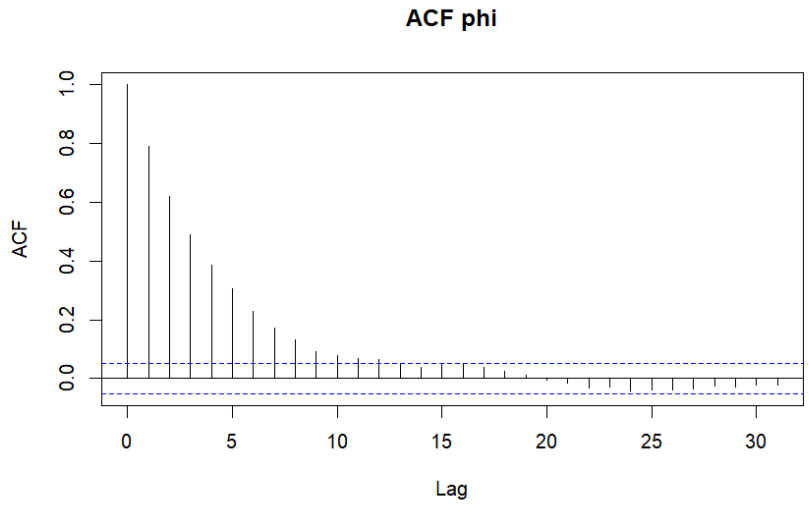


Figura 8: Funzione di autocorrelazione (ACF) dei campioni posteriori di ϕ.

è tipico dei campionatori Metropolis–within–Gibbs per parametri di dipendenza spaziale e indica che, pur essendo presenti correlazioni seriali, la catena riesce comunque a decorrelarsi in un numero moderato di iterazioni. La scelta di applicare thinning risulta quindi appropriata per ridurre ulteriormente la dipendenza tra campioni successivi e ottenere un campione a posteriori più vicino all'indipendenza.

Punto 3

In questo punto si analizzano i campioni posteriori ottenuti dall'algoritmo Metropolis-within-Gibbs (Punto 2) tramite: (1) diagnostica delle catene (traceplot e ACF), (2) valutazione dell'effetto delle coordinate tramite intervalli credibili per β_1, β_2, (3) stima a posteriori della funzione di covarianza spaziale $C(h; \phi)$ e del relativo intervallo credibile al 95%.

Autocorrelation Function (ACF). Poiché i campioni MCMC sono dipendenti, si valuta la correlazione seriale tramite l'ACF:

$$r(h) = \frac{\sum_{b=1}^{N-h}(\theta_b - \bar{\theta})(\theta_{b+h} - \bar{\theta})}{\sum_{b=1}^{N}(\theta_b - \bar{\theta})^2},$$

che se si annulla rapidamente implica campioni quasi indipendenti; se invece l'ACF resta alta per molti lag, conviene aumentare il thinning.

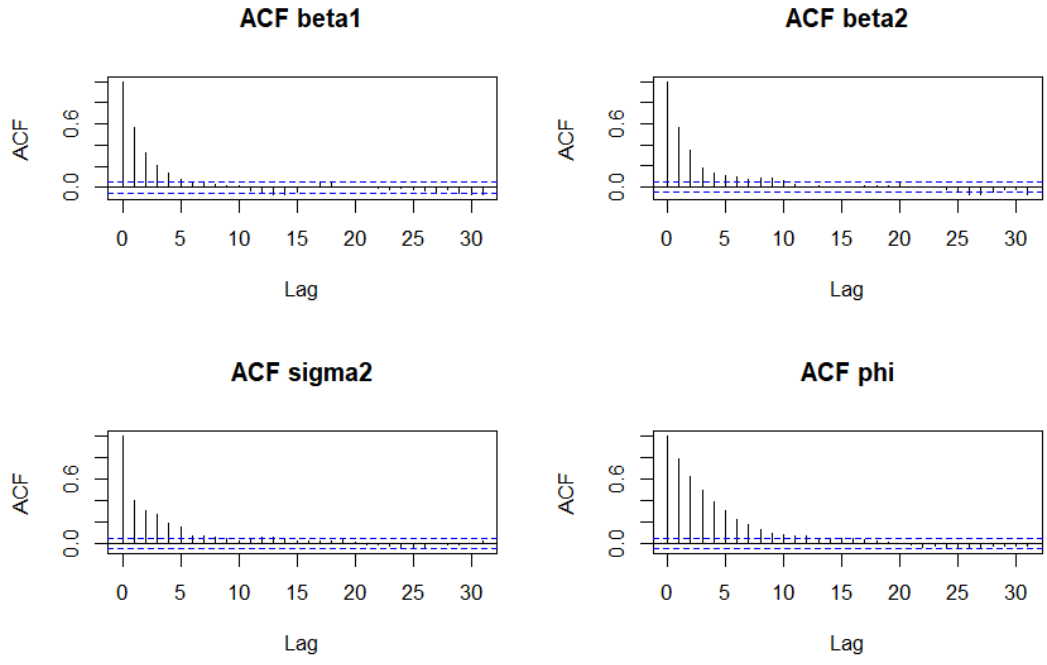


Figura 9: ACF dei campioni posteriori per β_1, β_2, σ^2 e ϕ.

Interpretazione delle ACF ottenute. Dalla Figura 9 si nota autocorrelazione positiva ai primi lag, che tende a ridursi entro un numero moderato di lag. Questo suggerisce che il thinning scelto risulta ragionevole per ridurre ulteriormente la dipendenza tra campioni consecutivi.

Obiettivo. Il modello include un termine di trend deterministico:

$$m(s) = \mu + \beta_1 s_1 + \beta_2 s_2,$$

per ottenere un gradiente spaziale di larga scala. Per valutare se le coordinate hanno un effetto significativo sul log(PM10), si studiano le marginali posteriori di β_1 e β_2.

Calcoli a posteriori (media, deviazione standard, quantili). Dato un campione MCMC dei coefficienti

$$\{\beta^{(b)}\}_{b=1}^{B}, \quad \beta^{(b)} = (\mu^{(b)}, \beta_1^{(b)}, \beta_2^{(b)}),$$

si calcolano statistiche empiriche:

- **Media a posteriori**:

$$\widehat{\mathbb{E}}(\beta_j \mid y) = \frac{1}{B}\sum_{b=1}^{B} \beta_j^{(b)};$$

- **Deviazione standard a posteriori**:

$$\widehat{\mathrm{sd}}(\beta_j \mid y) = \sqrt{\frac{1}{B-1}\sum_{b=1}^{B}\Big(\beta_j^{(b)} - \bar{\beta}_j\Big)^2};$$

- **Intervallo credibile al 95%** tramite quantili empirici:

$$IC_{0.95}(\beta_j) = \big[q_{0.025}(\beta_j),\ q_{0.975}(\beta_j)\big].$$

Criterio di significatività Bayesiano. Un modo per valutare l'evidenza dell' effetto è verificare se lo 0 è contenuto nell'intervallo credibile al 95%:

- se $0 \notin IC_{0.95}(\beta_j)$, c'è evidenza a posteriori che β_j sia diverso da 0;
- se $0 \in IC_{0.95}(\beta_j)$,non c'è evidenza (pur potendo essere diverso da 0 con probabilità non trascurabile).

Funzione di covarianza spaziale $C(h;\phi)$: media e intervallo credibile

Per il processo spaziale $W(s)$ si assume covarianza esponenziale:

$$C(h;\phi) = \sigma^2 \exp(-\phi h),$$

dove h è la distanza tra due punti.

Costruzione della griglia di distanze. Si sceglie un insieme di distanze

$$h_1, \ldots, h_K \in [0, d_{\max}],$$

dove $d_{\max}$ è la massima distanza osservata tra coppie di stazioni. Questo permette di rappresentare come la dipendenza stimata varia da distanza nulla fino alla scala spaziale massima disponibile nei dati.

Campioni posteriori di $C(h)$. Disponendo dei campioni MCMC $\{(\sigma^{2(b)}, \phi^{(b)})\}_{b=1}^{B}$, per ogni distanza h_k si costruisce:

$$C^{(b)}(h_k) = \sigma^{2(b)} \exp\big(-\phi^{(b)} h_k\big), \qquad b = 1, \ldots, B.$$

Quindi, per ogni h_k, si calcolano:

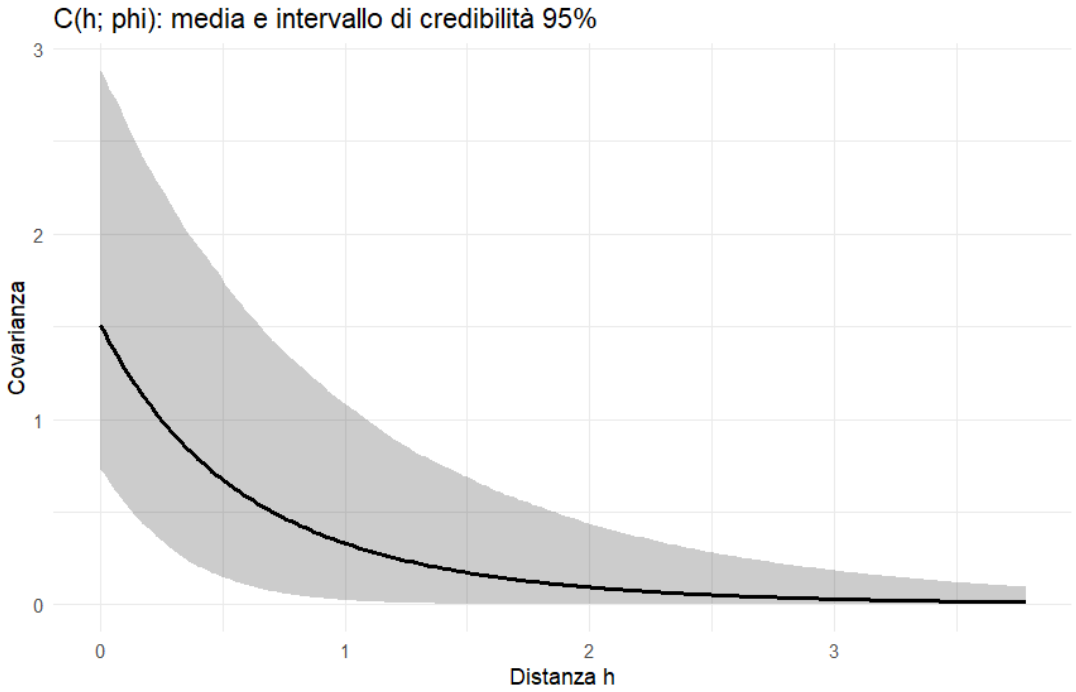


Figura 10: Stima a posteriori di $C(h;\phi) = \sigma^2 e^{-\phi h}$: linea nera = media a posteriori; fascia grigia = intervallo credibile 95%.

- **media a posteriori**:

$$\widehat{\mathbb{E}}(C(h_k) \mid y) = \frac{1}{B}\sum_{b=1}^{B} C^{(b)}(h_k);$$

- **intervallo credibile al 95%**:

$$\big[q_{0.025}(C(h_k)),\ q_{0.975}(C(h_k))\big],$$

usando quantili empirici dei valori $\{C^{(b)}(h_k)\}_{b=1}^{B}$.

Interpretazione del grafico di $C(h)$. Dalla Figura 10 si osserva:

- a $h = 0$, la covarianza coincide con $C(0) = \sigma^2$, quindi l'altezza iniziale della curva riflette la varianza spaziale stimata della componente $W(s)$;
- la curva decresce rapidamente con h, come previsto dalla forma esponenziale; il tasso di decadimento è governato da ϕ (valori più grandi di ϕ implicano decadimento più rapido);
- la fascia di credibilità si allarga a distanze più grandi: ciò riflette maggiore incertezza sulla dipendenza a lungo raggio, tipicamente meno informata dai dati osservati (soprattutto se ci sono poche coppie a distanze vicine a $d_{\max}$).

Rappresentazione del processo spaziale $W(s)$ e confronto con i dati

In questa sezione si analizza il processo spaziale latente $W(s)$, che rappresenta la componente di dipendenza spaziale residua del modello, ossia la parte di variabilità del log(PM10) non spiegata dal trend deterministico $\mu + \beta_1 s_1 + \beta_2 s_2$. L'analisi è condotta utilizzando i campioni a posteriori di $W(s)$ ottenuti dall'algoritmo Metropolis-within-Gibbs descritto nei punti precedenti.

Campioni posteriori di $W(s)$

Durante l'MCMC, dopo burn-in e thinning, per ciascun punto spaziale osservato s_i sono stati salvati K campioni:

$$\{W^{(1)}(s_i), \ldots, W^{(K)}(s_i)\}.$$

Questi campioni approssimano la distribuzione a posteriori marginale di $W(s_i) \mid \mathbf{y}$. Le quantità a posteriori di interesse possono essere stimate tramite statistiche empiriche calcolate su tali campioni.

Per ogni punto spaziale s_i si calcolano:

Media a posteriori

$$M(s_i) = \mathbb{E}\big[W(s_i) \mid \mathbf{y}\big] \approx \frac{1}{K} \sum_{k=1}^{K} W^{(k)}(s_i),$$

che fornisce una stima puntuale della componente spaziale strutturata.

Intervallo di credibilità al 95%

$$IC_{0.95}(W(s_i)) = \big[Q_{0.025}(W(s_i)),\ Q_{0.975}(W(s_i))\big],$$

dove Q_p indica il quantile empirico di ordine p dei campioni posteriori. L'ampiezza dell'intervallo,

$$\text{amp}(s_i) = Q_{0.975}(W(s_i)) - Q_{0.025}(W(s_i)),$$

misura l'incertezza a posteriori associata alla stima di $W(s_i)$.

Mappa della media a posteriori di $W(s)$

La Figura 11 rappresenta la media a posteriori di $W(s)$ nei punti osservati. Si osservano aree contigue con valori simili, evidenziando una struttura spaziale liscia e coerente con l'assunzione di processo Gaussiano stazionario con covarianza esponenziale. In particolare, zone con valori positivi di $M(s)$ indicano aree in cui il livello di PM10 è sistematicamente più alto rispetto a quanto spiegato dal trend deterministico, mentre valori negativi indicano aree con livelli inferiori alla media attesa dal solo trend.

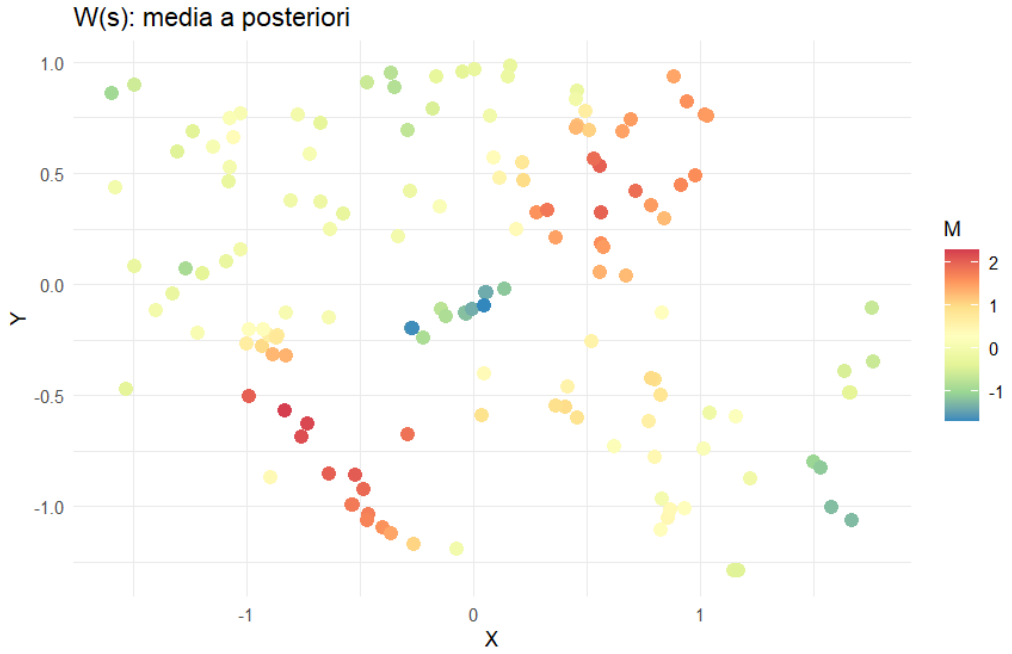


Figura 11: Mappa della media a posteriori $M(s)$ del processo spaziale latente $W(s)$.

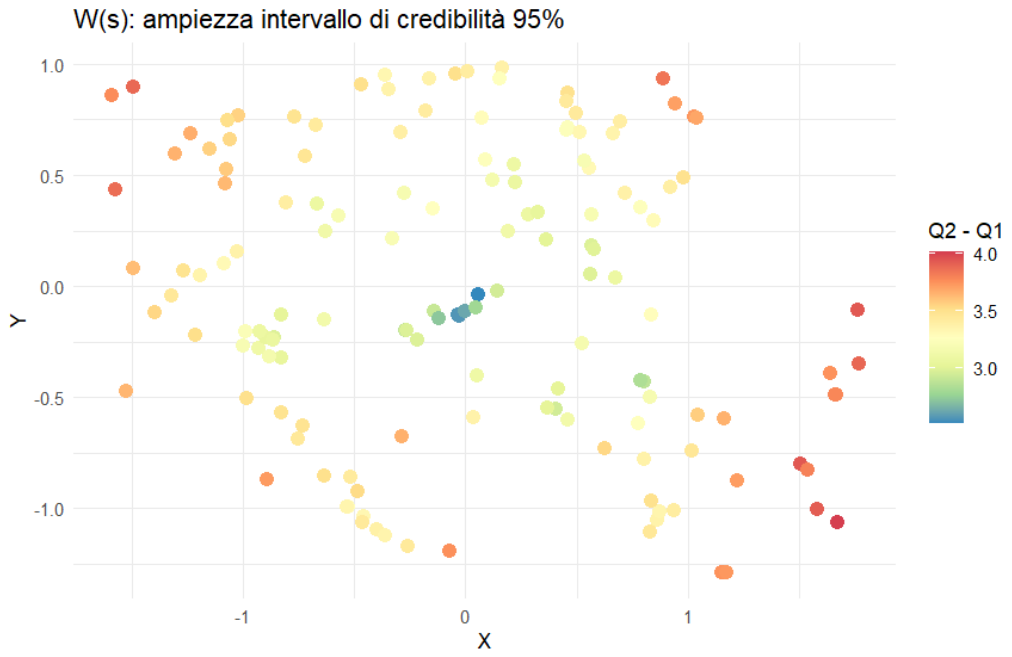


Figura 12: Ampiezza dell'intervallo di credibilità al 95% di $W(s)$: $Q_{0.975} - Q_{0.025}$.

Mappa dell'incertezza: ampiezza dell'intervallo di credibilità

La Figura 12 mostra la distribuzione spaziale dell'ampiezza dell'intervallo di credibilità di $W(s)$. Valori elevati indicano maggiore incertezza a posteriori, tipicamente associata a regioni con minore informazione disponibile o più isolate spazialmente. Al contrario, punti circondati da molte osservazioni mostrano intervalli più stretti, quindi: l'informazione viene condivisa tra punti vicini attraverso la struttura di covarianza.

Confronto tra $W(s)$ e $Y(s)$ osservato

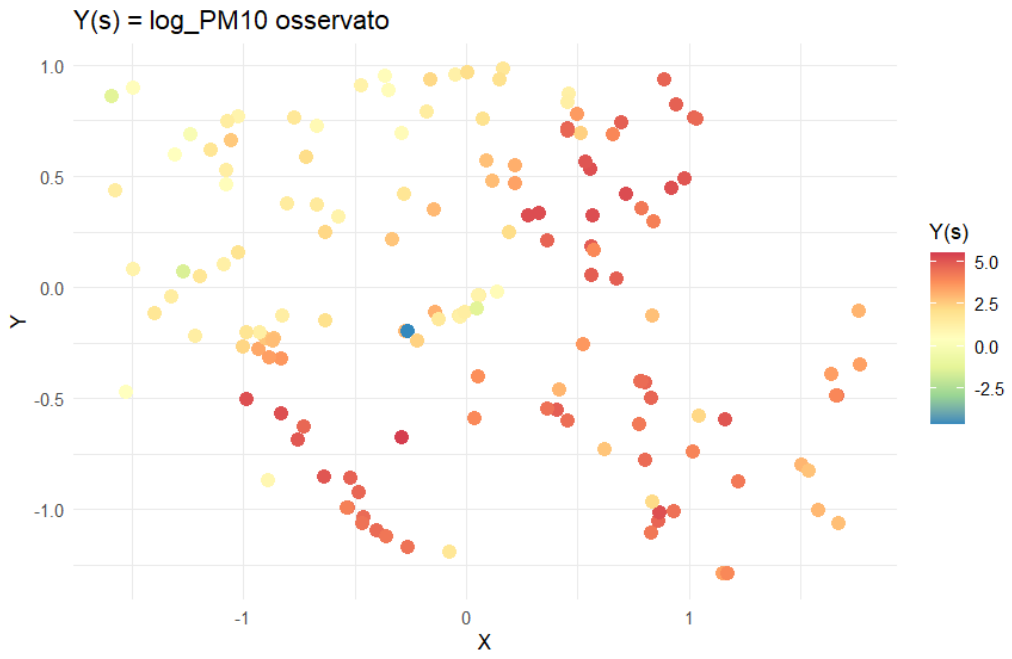


Figura 13: Mappa dei valori osservati $Y(s) = \log(\text{PM10})$.

La Figura 13 riporta la mappa dei valori osservati del log(PM10). Confrontando questa figura con la mappa della media a posteriori di $W(s)$ (Figura 11), si nota che molte delle strutture spaziali presenti nei dati osservati vengono riprodotte dalla componente $W(s)$. Ciò conferma che il processo Gaussiano cattura efficacemente la dipendenza spaziale residua non spiegata dal trend deterministico.
In particolare, il confronto evidenzia come il modello decomponga il segnale osservato in:

- una componente di larga scala (trend nelle coordinate);
- una componente spaziale $W(s)$;
- una componente di rumore $\varepsilon(s)$.

Questa scomposizione è uno dei principali vantaggi dei modelli spaziali Bayesiani basati su processi Gaussiani.
Nel complesso, l'analisi di $W(s)$ mostra che:

- esiste una chiara struttura spaziale residua nel log(PM10);
- il processo Gaussiano fornisce una stima liscia e interpretabile di tale struttura;
- l'incertezza associata a $W(s)$ varia nello spazio in modo coerente con la distribuzione delle osservazioni.

Punto 4: Predizione del processo spaziale sulla griglia e mappe di incertezza

La consegna richiede, per ogni punto della griglia regolare s_0, di ottenere campioni dalla distribuzione a posteriori di $W(s_0) \mid \mathbf{y}$, calcolare media e intervalli credibili e rappresentarli graficamente su tutta l'area.
L'idea teorica alla base è la seguente: nel modello GP, condizionatamente ai parametri (σ^2, ϕ), il vettore dei valori latenti osservati $\mathbf{w} = (W(s_1), \ldots, W(s_n))^\top$ e i valori latenti nei punti di griglia $\mathbf{w}_0 = (W(s_{0,1}), \ldots, W(s_{0,m}))^\top$ hanno una distribuzione congiunta normale multivariata. Dunque la distribuzione condizionata $\mathbf{w}_0 \mid \mathbf{w}, \sigma^2, \phi$ è ancora normale ed è ottenibile in forma chiusa. Questo è un risultato standard dei processi gaussiani (condizionamento di una normale multivariata).

Notazione e matrici di covarianza

Siano:

$$S = \{s_1, \ldots, s_n\} \quad \text{(punti osservati)}, \qquad S_0 = \{s_{0,1}, \ldots, s_{0,m}\} \quad \text{(punti griglia)}.$$

Definiamo le matrici di distanza:

$$H_{oo} = (h_{ij})_{i,j=1}^{n}, \qquad h_{ij} = \|s_i - s_j\|,$$
$$H_{og} = (h_{i\ell})_{i=1,\ldots,n}^{\ell=1,\ldots,m}, \qquad h_{i\ell} = \|s_i - s_{0,\ell}\|.$$

Nel codice:

- `dist(coords_mat)` produce H_{oo};
- `D_obs_grid` è ottenuta costruendo le distanze sulla matrice unita `rbind(coords_mat, coords_grid)` e poi estraendo il blocco osservati–griglia, cioè H_{og}.

Per covarianza esponenziale:

$$C(h; \phi) = \sigma^2 \exp(-\phi h).$$

Quindi, fissati (σ^2, ϕ), si ottengono:

$$\Sigma_{oo} = \sigma^2 R_{oo}, \qquad [R_{oo}]_{ij} = \exp(-\phi\, h_{ij}),$$
$$\Sigma_{og} = \sigma^2 R_{og}, \qquad [R_{og}]_{i\ell} = \exp(-\phi\, h_{i\ell}).$$

Distribuzione condizionata e formula della media

Per ogni iterazione MCMC b, si dispone di un campione dei parametri $(\sigma^{2(b)}, \phi^{(b)})$ e del vettore osservato $\mathbf{w}^{(b)}$ (salvato in `w_save`). La teoria dei GP implica che:

$$\mathbf{w}_0 \mid \mathbf{w}, \sigma^2, \phi \sim \mathcal{N}\Big(\Sigma_{go}\Sigma_{oo}^{-1}\mathbf{w},\ \Sigma_{gg} - \Sigma_{go}\Sigma_{oo}^{-1}\Sigma_{og} \Big),$$

dove $\Sigma_{go} = \Sigma_{og}^\top$.
Nel codice si calcola (per ciascun b) la **media condizionata**:

$$\mathbb{E}\big[\mathbf{w}_0 \mid \mathbf{w}^{(b)}, \sigma^{2(b)}, \phi^{(b)}\big] = \Sigma_{go}^{(b)} \left(\Sigma_{oo}^{(b)}\right)^{-1} \mathbf{w}^{(b)}.$$

Questa è esattamente la formula implementata:

- si costruisce $\Sigma_{oo}^{(b)} = \sigma^{2(b)} R_{oo}(\phi^{(b)})$;
- si costruisce $\Sigma_{og}^{(b)} = \sigma^{2(b)} R_{og}(\phi^{(b)})$;
- si calcola $a = \left(\Sigma_{oo}^{(b)}\right)^{-1} \mathbf{w}^{(b)}$;
- si ottiene la media predittiva come

$$\texttt{mean_pred} = \Sigma_{go}^{(b)} a = \left(\Sigma_{og}^{(b)}\right)^{\top} a.$$

Nota Sono richiesti "campioni a posteriori di $W(s_0) \mid \mathbf{y}$". Un modo rigoroso è:

$$W(s_0) \mid \mathbf{y} = \int W(s_0) \mid \mathbf{w}, \sigma^2, \phi \; f(\mathbf{w}, \sigma^2, \phi \mid \mathbf{y}) \, d\mathbf{w} \, d\sigma^2 \, d\phi.$$

L'approccio implementato realizza un campionamento Monte Carlo sulla posterior di $(\mathbf{w}, \sigma^2, \phi)$ usando l'MCMC, e per ciascun campione calcola la media condizionata $\Sigma_{go}\Sigma_{oo}^{-1}\mathbf{w}$. Questo produce un' approssimazione della distribuzione predittiva: si salva solo la media condizionata e non si aggiunge la variabilità residua della normale condizionata (la matrice di varianza condizionata).

Per calcolare $\left(\Sigma_{oo}^{(b)}\right)^{-1} \mathbf{w}^{(b)}$ non si usa l'inversa esplicita (numericamente instabile e costosa), ma la fattorizzazione di Cholesky:

$$\Sigma_{oo}^{(b)} = LL^{\top},$$

con L triangolare superiore (in `R`, `chol` restituisce un triangolare superiore). Si risolvono poi due sistemi triangolari:

$$L^{\top} z = \mathbf{w}^{(b)} \quad \Rightarrow \quad z, \qquad La = z \quad \Rightarrow \quad a = \left(\Sigma_{oo}^{(b)}\right)^{-1} \mathbf{w}^{(b)}.$$

Nel codice questo è implementato come:

- `L <- chol(Sigma_obs)`
- `a <- backsolve(L, forwardsolve(t(L), w_b))`

che equivale a calcolare $\Sigma_{oo}^{-1}\mathbf{w}$ in modo stabile.

Costruzione dei campioni su griglia e riassunti posteriori

Ripetendo la procedura per $b = 1, \ldots, B$ iterazioni salvate, si ottiene una matrice:

$$W_{\text{grid}} \in \mathbb{R}^{B \times m},$$

dove la riga b contiene i valori predetti (media condizionata) nei m punti di griglia:

$$W_{\text{grid}}[b, \ell] \approx \mathbb{E}[W(s_{0,\ell}) \mid \mathbf{w}^{(b)}, \sigma^{2(b)}, \phi^{(b)}].$$

A questo punto si calcolano, per ogni punto di griglia $s_{0,\ell}$:

$$M_{\text{grid}}(s_{0,\ell}) = \frac{1}{B} \sum_{b=1}^{B} W_{\text{grid}}[b, \ell],$$

$$Q1_{\text{grid}}(s_{0,\ell}) = q_{0.025}\{W_{\text{grid}}[1,\ell],\ldots,W_{\text{grid}}[B,\ell]\}, \quad Q2_{\text{grid}}(s_{0,\ell}) = q_{0.975}(\cdot).$$

Queste quantità sono esattamente quelle richieste: media e limiti inferiore/superiore dell'intervallo credibile al 95%.

Poiché la griglia è regolare e copre l'intera area, la rappresentazione più informativa è una mappa tramite `geom_tile`, che assegna un colore a ciascuna cella della griglia.

Media a posteriori di $W(s)$ sulla griglia

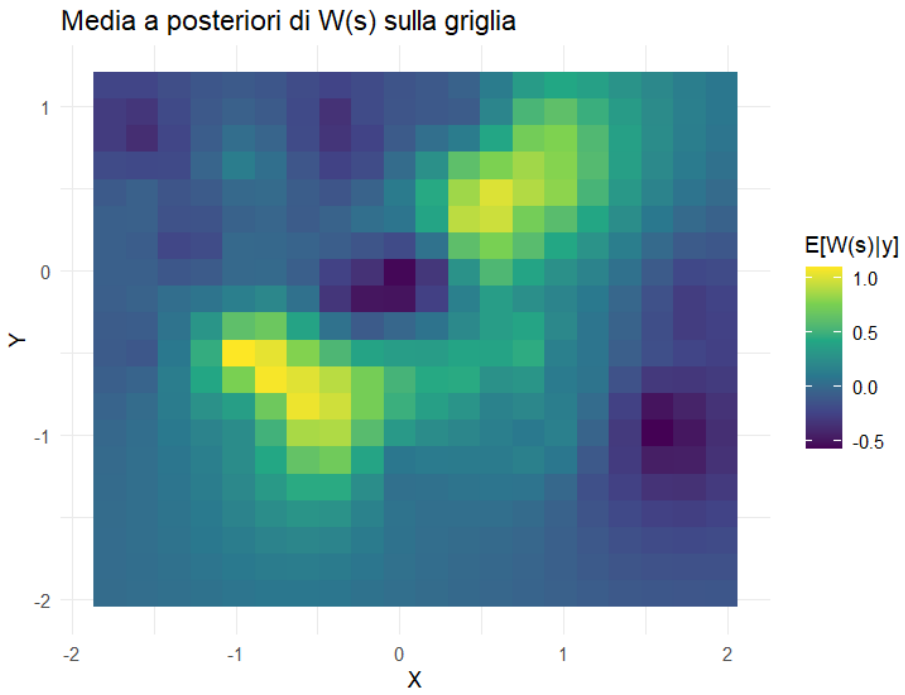


Figura 14: Media a posteriori di $W(s)$ sulla griglia: $M_{\text{grid}}(s_0) = \mathbb{E}[W(s_0) \mid \mathbf{y}]$ approssimata via Monte Carlo.

La Figura 14 mostra la superficie stimata della componente spaziale. A differenza della mappa puntuale del Punto 3 (valutata solo nei punti osservati), qui si ottiene una superficie continua che copre l'intera regione. Le aree con valori positivi indicano zone in cui, a parità di trend deterministico, il processo tende ad aumentare il log(PM10); le aree negative indicano l'opposto. La continuità spaziale è coerente con la covarianza esponenziale: punti vicini sono fortemente correlati e quindi la superficie tende a variare gradualmente.

Limite inferiore dell'intervallo credibile 95%

La Figura 15 rappresenta il quantile 2.5% della distribuzione a posteriori approssimata in ciascun punto di griglia. Dove $Q1$ risulta molto negativo, si ha evidenza che $W(s_0)$ sia verosimilmente sotto zero con alta credibilità. Viceversa, aree in cui $Q1$ è vicino a zero o positivo indicano che l'effetto spaziale potrebbe essere nullo o positivo.

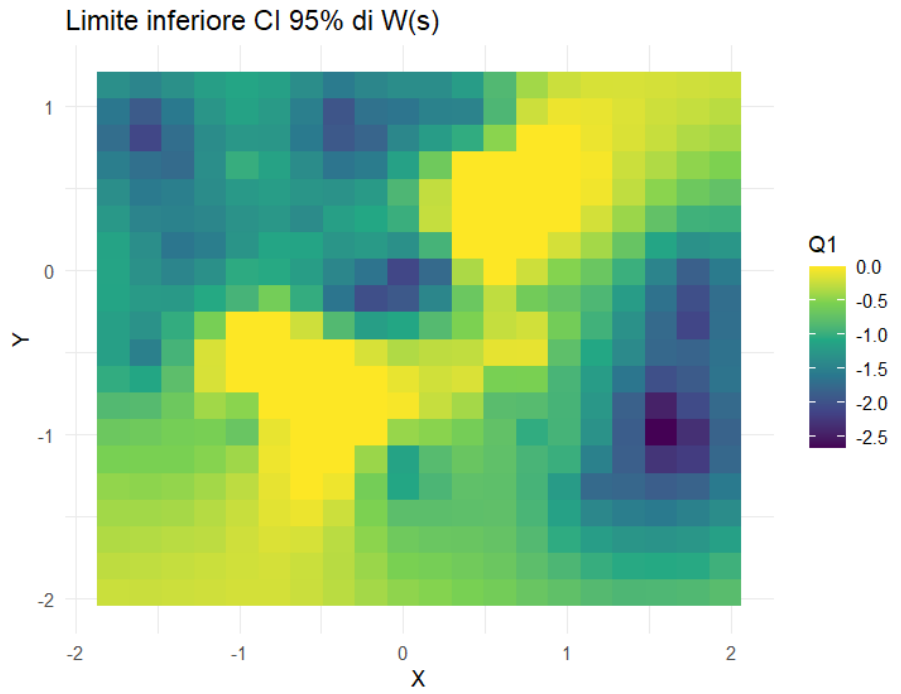


Figura 15: Limite inferiore $Q1_{\text{grid}}(s_0)$ dell'intervallo credibile al 95% di $W(s_0)$.

Limite superiore dell'intervallo credibile 95%

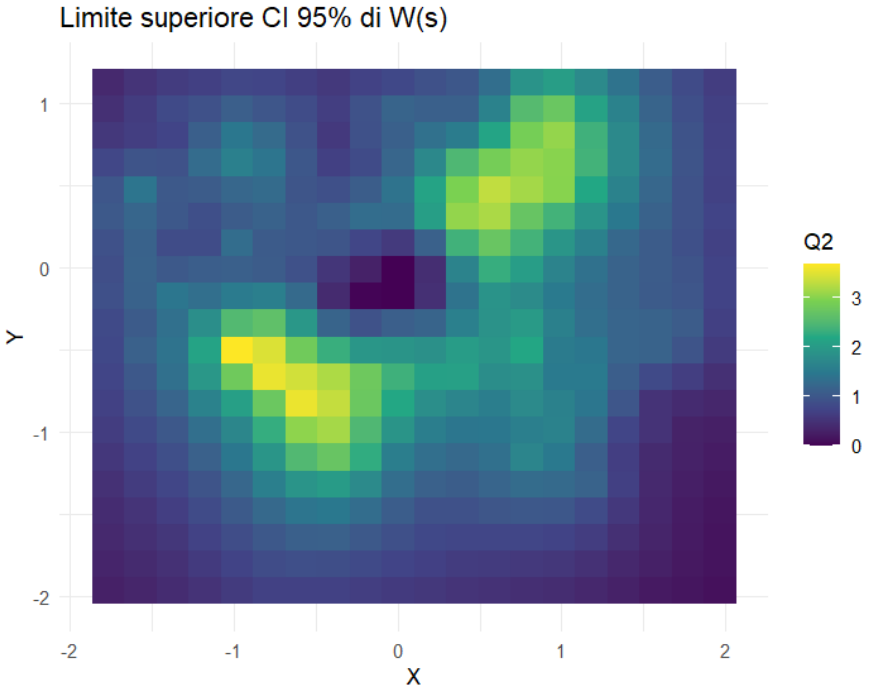


Figura 16: Limite superiore $Q2_{\text{grid}}(s_0)$ dell'intervallo credibile al 95% di $W(s_0)$.

La Figura 16 mostra il quantile 97.5%. Aree con $Q2$ molto positivo indicano regioni in cui il processo latente può assumere valori elevati con credibilità significativa. Combinando $Q1$ e $Q2$ si ottiene un quadro completo dell'incertezza locale: ad esempio, se in una zona

$Q1 > 0$ allora $W(s_0)$ è positivo con credibilità 95%; se $Q2 < 0$ allora è negativo con credibilità 95%; se invece $Q1 < 0 < Q2$ allora il segno non è determinato con alta credibilità (incertezza più elevata).